



INSTITUTO SUPERIOR DE ENGENHARIA DE LISBOA (ISEL)

DEPARTAMENTO DE ENGENHARIA ELETRÓNICA E DE
TELECOMUNICAÇÕES E COMPUTADORES (DEETC)

LEIM

LICENCIATURA EM ENGENHARIA INFORMÁTICA E MULTIMÉDIA

UNIDADE CURRICULAR DE PROJETO

Projeto 56 – Deal Rank

Autores

Rafael Saraiva (47484)

Mariana Almeida (49749)

Orientador

Professor Hélder Bastos

Engenheiro Rafael Santos

Julho, 2025

Resumo

O presente projeto foi desenvolvido no âmbito do projeto final do curso de Engenharia Informática e Multimédia do Instituto Superior de Engenharia de Lisboa, em parceria com a startup neerlandesa BARTER. A BARTER opera numa plataforma que promove interações entre empresas (partners) e criadores de conteúdo (creators) através de propostas de colaboração (deals).

No entanto, a aplicação móvel atual apresenta uma limitação importante que afeta a experiência de utilização dos creators: todas as propostas são apresentadas cronologicamente, de forma igual para todos os utilizadores, sem qualquer nível de personalização. Este comportamento limita a eficiência do processo de correspondência entre creators e deals, reduzindo o potencial das interações. O objetivo do projeto realizado surge precisamente neste contexto: propor uma solução que permita personalizar o conjunto de deals apresentados a cada creator, de acordo com o seu perfil e interesses específicos.

A solução desenvolvida baseia-se em técnicas de representação semântica e pesquisa por similaridade. A abordagem implementada utiliza Large Language Models para gerar embeddings a partir das descrições textuais das propostas e dos criadores. Estes embeddings são posteriormente processados através de técnicas de indexação e pesquisa vetorial, mais especificamente pela biblioteca FAISS, permitindo a construção de rankings personalizados de propostas com elevado nível de precisão e relevância. A metodologia adotada seguiu uma abordagem dividida em etapas sequenciais: análise conceptual, definição de requisitos, desenvolvimento de arquitetura, implementação e validação experimental através de testes sintéticos. Esta metodologia assegurou um desenvolvimento sistemático e fundamentado da solução proposta.

Os resultados obtidos demonstram que o sistema desenvolvido responde às necessidades identificadas, proporcionando personalização dos conteúdos apresentados aos creators. O sistema revelou-se adequado para integração na plataforma existente da BARTER, contribuindo para uma melhoria da experiência dos utilizadores. Este trabalho representa um contributo significativo ao combinar tecnologias de processamento de linguagem natural com técnicas de pesquisa vetorial, resultando numa solução eficiente e escalável para recomendação personalizada de conteúdos.

Palavras-Chave: Creators, Deals, Recomendação Personalizada, Representação Semântica, Pesquisa por Similaridade, Large Language Models, Embeddings, FAISS

Abstract

This project was developed as part of the final project for the Computer and Multimedia Engineering course at the Instituto Superior de Engenharia de Lisboa, in partnership with the Dutch startup BARTER. BARTER operates a platform that promotes interactions between companies (partners) and content creators (creators) through collaboration proposals (deals).

However, the current mobile application presents an important limitation that affects the user experience of creators: all proposals are presented chronologically, in the same way for all users, without any level of personalization. This behavior limits the efficiency of the matching process between creators and deals, reducing the potential of interactions. The objective of the project carried out arises precisely in this context: to propose a solution that allows personalizing the set of deals presented to each creator, according to their profile and specific interests.

The developed solution is based on semantic representation techniques and similarity search. The implemented approach uses Large Language Models to generate embeddings from textual descriptions of proposals and creators. These embeddings are subsequently processed through indexing and vector search techniques, more specifically through the FAISS library, enabling the construction of personalized proposal rankings with high levels of precision and relevance. The adopted methodology followed an approach divided into sequential stages: conceptual analysis, requirements definition, architecture development, implementation and experimental validation through synthetic tests. This methodology ensured a systematic and well-founded development of the proposed solution.

The obtained results demonstrate that the developed system responds to the identified needs, providing personalization of content presented to creators. The system proved suitable for integration into BARTER's existing platform, contributing to an improvement in user experience. This work represents a significant contribution by combining natural language processing technologies with vector search techniques, resulting in an efficient and scalable solution for personalized content recommendation.

Keywords: Creators, Deals, Personalized Recommendation, Semantic Representation, Similarity Search, Large Language Models, Embeddings, FAISS

Índice

Resumo	i
Abstract	iii
Índice	v
Lista de Tabelas	vii
Lista de Figuras	ix
1 Introdução	1
2 Trabalho Relacionado	3
3 Modelo Proposto	5
3.1 Requisitos	5
3.1.1 Casos de Utilização	5
3.2 Fundamentos	6
3.2.1 Arquitetura Model-View-Controller (MVC)	6
3.2.2 TF-IDF	7
3.2.3 Embeddings	7
3.2.4 Large Language Models (LLMs)	7
3.2.5 Ollama	8
3.2.6 Nomic Embed Text (v1.5 e v2)	8
3.2.7 FAISS	9
3.2.8 Flask	10
3.3 Abordagem	11
3.3.1 Tratamento dos Dados dos Datasets	11

3.3.2	Simulação da Base de Dados da BARTER	13
3.3.3	Codificação das Informações de Deals e Creators	13
3.3.4	Cálculo de Similaridade entre Deals e Creators	14
4	Implementação do Modelo	17
4.1	Módulo de Tratamento dos Dados dos Datasets	17
4.2	Organização Modular e Arquitetura MVC	18
4.3	Estrutura e Funcionamento do Webservice	19
4.3.1	Rotas	20
4.4	Estrutura e Funcionamento do Modelo	21
4.4.1	Classe <code>SystemManager</code>	22
4.4.2	Classe <code>StartupManager</code>	23
4.4.3	Sub-packages creator e deal	24
4.4.4	Sub-package Embeddings	25
4.5	Estrutura e Funcionamento da Base de Dados Simulada	27
4.6	Interface Web	29
5	Validação e Testes	31
5.1	Objetivo da Validação	31
5.2	Dados de Teste Utilizados	31
5.2.1	Creators	32
5.2.2	Deals	33
5.3	Metodologia de Teste	35
5.4	Critérios de Validação	35
5.5	Resultados Obtidos	36
5.5.1	Resultados para o Creator 1	36
5.5.2	Resultados para o Creator 4	39
5.5.3	Resultados para o Creator 5	45
5.5.4	Resultados para o Creator 7	51
5.6	Discussão dos Resultados	55
5.6.1	Coerência Temática	55
5.6.2	Distâncias	56
6	Conclusões e Trabalho Futuro	57
	Bibliografia	61

Lista de Tabelas

3.1	Comparação entre duas Soluções para o Tratamento de Dados. . . .	12
5.1	Descrições sintéticas dos creators de teste	32
5.2	Descrições sintéticas dos deals de teste	35
5.3	Ranking do Creator 1	39
5.4	Ranking do Creator 4	45
5.5	Ranking do Creator 5	50
5.6	Ranking do Creator 7	55

Lista de Figuras

3.1	Diagrama dos Casos de Utilização	6
3.2	Testes de Tradução	13
4.1	Processo de filtragem dos datasets originais	18
4.2	Processo de limpeza e tradução dos textos dos datasets	18
4.3	Arquitetura geral do sistema.	18
4.4	Estrutura do Webservice	20
4.5	SystemManager e StartupManager	22
4.6	Sub-packages Creator e Deal	24
4.7	Sub-package Embeddings	26
4.8	Estrutura da Base de Dados Simulada	28
4.9	Interface sem Resultados	30
4.10	Interface com Apresentação de Resultados	30

Capítulo 1

Introdução

O presente relatório descreve o projeto desenvolvido no âmbito do projeto final do curso de Engenharia Informática e Multimédia do Instituto Superior de Engenharia de Lisboa, em colaboração com a startup neerlandesa BARTER. A BARTER desenvolveu uma plataforma tecnológica que visa tornar acessível, às empresas, o mercado dos criadores de conteúdo (designados **creators**). Através da aplicação móvel disponibilizada pela BARTER, as empresas (**partners**) divulgam propostas de colaboração, denominadas por **deals**, às quais os creators se podem candidatar, oferecendo em troca conteúdos nas suas redes sociais, beneficiando dos produtos ou serviços disponibilizados.

No entanto, a aplicação móvel atual apresenta uma limitação importante que afeta a experiência de utilização dos creators: todas as propostas são apresentadas cronologicamente, de forma igual para todos os utilizadores, sem qualquer nível de personalização. Este comportamento limita a eficiência do processo de correspondência entre creators e deals, reduzindo o potencial das interações. O objetivo do projeto realizado surge precisamente neste contexto: propor uma solução que permita personalizar o conjunto de deals apresentados a cada creator, de acordo com o seu perfil e interesses específicos.

A solução desenvolvida neste projeto introduz uma abordagem baseada em técnicas modernas de representação semântica e pesquisa por similaridade. Em concreto, cada deal e cada creator são representados numericamente através de vetores (**embeddings**), gerados a partir das suas descrições textuais, com recurso a **Large Language Models (LLMs)**. Estes embeddings são posteriormente comparados utilizando técnicas de indexação e pesquisa vetorial (**FAISS**), permitindo construir rankings personalizados de propostas para cada creator com um

elevado nível de precisão e relevância. O projeto apresenta-se como um contributo significativo, utilizando uma combinação inovadora de tecnologias modernas para o desenvolvimento de uma solução eficiente, precisa e escalável.

Durante o processo de desenvolvimento, foi adotada uma metodologia de trabalho dividida em etapas: análise conceptual, definição de requisitos, desenvolvimento de arquitetura, implementação e validação experimental através de testes sintéticos. No que diz respeito aos objetivos definidos no início do trabalho, consideraram-se alcançados. O sistema desenvolvido responde às necessidades identificadas, permitindo a personalização eficaz dos conteúdos apresentados, contribuindo assim para uma melhoria significativa das experiências dos utilizadores. Para além disso, o sistema mostrou-se robusto, escalável e pronto a ser adaptado para uma possível integração na aplicação da BARTER.

Capítulo 2

Trabalho Relacionado

A solução proposta neste projeto é a criação de um sistema de recomendação, isto é um mecanismo que ajuda a selecionar e ordenar itens que sejam, idealmente, pertinentes para um determinado perfil de utilizador, a partir de um conjunto bastante amplo de opções. O objetivo principal deste tipo de sistemas é a minimização da sobrecarga de informação, maximizando a probabilidade de correspondência entre os interesses e o conteúdo apresentado, promovendo uma experiência mais personalizada.

Como base estrutural e conceptual para a realização deste projeto, foi utilizado como referência o artigo Machine Learning Recommendation Systems [Google, 2025]. Este trabalho, disponibilizado pela empresa norte-americana, propõe uma visão para estes sistemas que acenta nas principais etapas: representação dos utilizadores e dos itens (vídeos, produtos, deals no caso deste projeto) através de uma codificação vetorial que preserve características, isto é, embeddings; ordenação (ranking) eficiente de embeddings com base em métricas de similaridade (distâncias como cosseno, euclidiana ou produto interno). No contexto deste projeto, recai um forte ênfase sobre estas duas componentes dos sistemas de recomendação.

Exemplos bastante conceituados da aplicação de sistemas de recomendação incluem o YouTube e a Netflix. No YouTube, um modelo gera embeddings para o contexto do utilizador e para cada vídeo. A similaridade entre os vetores, calculada através de produto interno, permite recuperar candidatos relevantes, que posteriormente passam por uma etapa de ranking ainda mais refinada [Covington et al., 2016]. Na Netflix, fontes de informação variadas (histórico de visualização, trends atuais, classificação baseada em estrelas de 1 a 5) alimentam modelos que geram conjuntos de candidatos, conjuntos estes que são posterior-

mente classificados e permitem criar múltiplas filas na interface do utilizador, com conteúdos personalizados[Gómez-Uribe e Hunt, 2015]. Ambos os casos adotam a estratégia referida no artigo da Google de representar, comparar e ordenar.

Sendo assim, este projeto posiciona-se como uma aplicação dos conceitos gerais de sistemas de recomendação a um cenário orientado à correspondência entre deals e creators, procurando inovar nos capítulos da geração de embeddings, utilizando LLMs localmente, sem dependências externas, e da construção eficiente do ranking, através de tecnologia moderna de comparação vetorial (FAISS), com a preocupação de desenvolver uma solução que seja escalável e robusta.

Capítulo 3

Modelo Proposto

Este capítulo apresenta o modelo de organização de deals por preferência, desenvolvido para a aplicação BARTER, definindo os requisitos funcionais e não funcionais que orientam o sistema, descrevendo os fundamentos teóricos e tecnológicos que sustentam a solução e detalhando a abordagem adotada.

3.1 Requisitos

Pretende-se que o sistema seja capaz de obter a totalidade dos dados de creators e deals disponíveis nos datasets e codificar essas informações de modo a preservar o seu significado. Esta codificação irá servir de base para o cálculo de similaridade entre todos os deals e cada creator, com a finalidade de construir uma lista ordenada com os dez deals mais próximos. Esta lista deverá ser apresentada ao utilizador dentro de limites de desempenho definidos: no máximo 200 ms. O sistema deve também disponibilizar as operações CRUD para gerir novos deals, remover deals que deixem de estar ativos ou atualizar propostas já existentes.

3.1.1 Casos de Utilização

É possível interagir com o sistema através de quatro cenários. No primeiro, Adicionar Deal, um partner cria uma nova proposta; o back-office envia os dados ao back-end, que gera o embedding correspondente e armazena-o no repositório. O segundo, Remover Deal, acontece quando um partner decide retirar uma proposta; o sistema recebe o identificador e elimina o embedding associado. É possível também um partner alterar o conteúdo de um deal já existente, Atualizar Deal, o embedding

é recalculado e substitui o original no repositório. Por fim, o cenário Obter Lista de Deals, que inicia quando um utilizador acede à aplicação; o back-office solicita o ranking associado a esse utilizador e o sistema retorna uma lista de dez deals ordenados por similaridade.




Figura 3.1: Diagrama dos Casos de Utilização

3.2 Fundamentos

Neste capítulo são abordados os principais conceitos e tecnologias necessários para compreender o projeto desenvolvido. São discutidos o padrão de arquitetura MVC, técnicas modernas de representação semântica de dados, tais como embeddings e Large Language Models (LLMs), bem como as tecnologias específicas utilizadas: Ollama, Nomic-embed-text (v1.5 e v2), FAISS e Flask.

3.2.1 Arquitetura Model-View-Controller (MVC)

A arquitetura Model-View-Controller é um padrão de arquitetura que promove uma clara separação de responsabilidades entre as componentes de uma aplicação, melhorando modularidade e manutenibilidade [Gamma et al., 1995]. O Model gere os dados, a lógica do negócio e as regras da aplicação, a View trata da apresentação e interação com o utilizador, e o Controller coordena a comunicação entre o utilizador e o modelo. O MVC permite que alterações numa camada

não influenciem negativamente as restantes, tornando-o especialmente adequado para aplicações web e sistemas distribuídos com elevado grau de interatividade [Fowler, 2002].

3.2.2 TF-IDF

O TF-IDF (Term Frequency-Inverse Document Frequency) é uma medida estatística, que tem como objetivo avaliar a importância de uma palavra num documento, combinando a frequência da mesma dentro do documento, com a raridade dessa palavra no conjunto total de documentos, de modo a realçar palavras que tenham mais significado. A componente TF mede a frequência de uma palavra no documento. Quanto mais vezes a palavra aparece, maior o seu peso. A componente IDF reflete quão comum ou rara é a palavra em todo o conjunto. Palavras muito frequentes (como “e”, “de”, “o”) recebem peso baixo, enquanto palavras raras ganham peso maior. O peso final de uma palavra é igual ao produto destas componentes. É possível, posteriormente, criar um vetor que contenha os pesos das palavras de um documento, permitindo calcular similaridades entre documentos. A grande vantagem desta técnica é a simplicidade de cálculo. No entanto, não é preservada a semântica das frases.

3.2.3 Embeddings

Embeddings são representações vetoriais densas, contínuas e de baixa dimensão que capturam relações semânticas complexas de palavras, frases ou documentos inteiros [Mikolov et al., 2013]. A grande vantagem dos embeddings é a capacidade de representar significados subtis através de operações matemáticas simples sobre vetores, permitindo, por exemplo, a comparação eficiente entre textos utilizando métricas geométricas como o cosseno ou distância Euclidiana. Embeddings pré-treinados tornaram-se padrão em tarefas de NLP (Natural Language Processing), devido à sua capacidade de generalização e robustez semântica [Pennington et al., 2014].

3.2.4 Large Language Models (LLMs)

Large Language Models (LLMs) são modelos de inteligência artificial treinados em enormes quantidades de texto, capazes de compreender e gerar texto natural com elevada precisão e fluência. Estes modelos, tipicamente baseados em arquiteturas Transformer [Vaswani et al., 2017], são treinados com até milhares de milhões de

parâmetros, permitindo uma excelente capacidade de generalização e representação semântica profunda do conhecimento linguístico [Brown et al., 2020]. Devido à sua versatilidade, LLMs são utilizados em diversas tarefas como tradução automática, geração de embeddings e recuperação semântica de informação.

3.2.5 Ollama

Ollama é um software open-source desenvolvido para simplificar o uso local de Large Language Models, oferecendo uma interface leve e rápida para execução destes modelos sem necessidade de ligação a serviços externos. Ao permitir que modelos sofisticados corram localmente com poucos recursos, Ollama elimina dependências externas, reduzindo custos e latências associadas a serviços na cloud, tornando-se ideal para projetos acadêmicos ou comerciais que exijam controle completo sobre os dados e privacidade [Ollama, 2024].

3.2.6 Nomic Embed Text (v1.5 e v2)

O nomic-embed-text é um modelo pré-treinado desenvolvido especificamente para a geração de embeddings textuais com elevada qualidade semântica, frequentemente utilizado em sistemas de pesquisa semântica. Este modelo utiliza uma arquitetura baseada em Transformers para representar textos em vetores numéricos, permitindo comparações semânticas eficientes e precisas, essenciais em tarefas que requerem recuperação rápida e robusta de informação textual [AI, 2024].

Os Transformers são redes neurais capazes de processar sequências de texto em paralelo, sem ter que processar uma palavra de cada vez. Utilizando o mecanismo de self-attention, é atribuído um peso consoante a relevância que uma palavra tem para com as restantes palavras do texto, resultando em pesos altos para relações com elevado significado e pesos baixos para relações com baixo significado. Estes pesos formam a representação contextual da palavra [Vaswani et al., 2017]. No nomic-embed-text, estas representações são, então, agregadas num único vetor que representa o significado da frase, criando um embedding. Este mecanismo permite distinguir palavras através da sua relevância contextual (ex: neste texto, palavras como “este”, “que” ou “da” seriam menos relevantes que palavras como “mecanismo”, “transformers” ou “significado”).

A versão v1.5 do nomic-embed-text demonstrou uma significativa capacidade de codificar textos, oferecendo embeddings que preservam relações semânticas detalha-

das e robustas. Esta versão popularizou-se rapidamente por apresentar resultados eficazes na comparação de documentos textuais, destacando-se especialmente em contextos que requerem compreensão semântica profunda. No que diz respeito ao suporte multilíngue, a versão v1.5 oferece bons resultados essencialmente para textos em inglês, apresentando desempenho razoável para idiomas europeus populares, como o francês, espanhol ou alemão. No entanto, para idiomas com menos recursos disponíveis ou com estruturas gramaticais significativamente diferentes do inglês, a qualidade dos embeddings gerados tende a decrescer, verificando-se limitações na captação das subtilezas linguísticas.

Com o lançamento da versão v2, houve uma melhoria substancial na capacidade de compreensão semântica e na captação de contextos complexos e relações linguísticas subtis. A v2 incorpora treino aperfeiçoado e ajustes na arquitetura transformer, oferecendo embeddings ainda mais representativos, precisos e contextualmente ricos. Adicionalmente, esta nova versão apresenta uma melhoria significativa no suporte multilíngue, abrangendo um maior número de idiomas para além do inglês com elevada qualidade semântica. Assim, além dos principais idiomas europeus, a versão v2 oferece representações robustas e precisas para outras línguas, incluindo idiomas asiáticos e eslavos, ampliando consideravelmente o seu campo de aplicação global. Estes avanços traduzem-se numa performance superior em tarefas como a pesquisa semântica avançada, recuperação de informação em larga escala e recomendação personalizada, permitindo representar textos complexos e multilíngues de forma mais exata e diferenciada em relação à versão anterior [AI, 2024].

3.2.7 FAISS

O FAISS (Facebook AI Similarity Search) é uma biblioteca especializada em pesquisa eficiente de vizinhos mais próximos (nearest-neighbor search) em espaços vetoriais de alta dimensão. A sua principal força reside na disponibilização de múltiplos tipos de índices que variam entre abordagens exatas e aproximadas, adequados a diferentes necessidades e contextos operacionais, permitindo assim aos utilizadores equilibrar critérios como precisão, velocidade e utilização de memória conforme o cenário específico da aplicação [Johnson et al., 2019]. Entre os vários tipos de índices disponíveis no FAISS, destacam-se os seguintes:

- **Índices Exatos (IndexFlat):** realizam pesquisa exaustiva, comparando o vetor de consulta com todos os vetores armazenados no índice. A grande

vantagem destes índices é a garantia absoluta de precisão na recuperação dos vizinhos mais próximos. Contudo, esta exatidão implica uma complexidade linear que pode tornar-se proibitiva em grandes volumes de dados.

- **Índices IVF (Inverted File Index):** dividem o espaço vetorial em clusters através de métodos como K-means, restringindo a pesquisa apenas aos clusters mais próximos ao vetor de consulta. Esta abordagem reduz drasticamente o tempo de pesquisa, com um compromisso muito ligeiro na precisão, sendo especialmente útil em bases de dados médias a grandes.
- **Índices HNSW (Hierarchical Navigable Small World Graph):** utilizam uma estrutura de grafos hierárquicos em que cada vetor é ligado aos seus vizinhos próximos em múltiplas camadas, permitindo uma pesquisa por similaridade com complexidade sub-linear. O índice **HNSWFlat**, em particular, oferece uma combinação muito favorável entre velocidade e precisão, permitindo adição e remoção dinâmica de vetores em tempo real, tornando-o altamente adequado para sistemas com atualizações frequentes.
- **Índices PQ (Product Quantization):** recorrem a técnicas avançadas de compressão vetorial através da quantização do espaço em sub-espacos menores, reduzindo significativamente os requisitos de memória e possibilitando que grandes quantidades de vetores sejam mantidos em RAM de forma eficiente. Este índice permite pesquisas muito rápidas com baixo consumo de memória, embora implique alguma perda adicional de precisão.
- **Índices IVF-PQ:** combinam as vantagens dos índices IVF e PQ, organizando primeiro os vetores em clusters (IVF) e posteriormente comprimindo cada vetor com product quantization (PQ). Desta forma, conseguem resultados de pesquisa rápidos, consumo reduzido de memória e escalabilidade eficiente para milhões ou até milhares de milhões de vetores, tornando-se ideais para grandes volumes de dados.

3.2.8 Flask

O Flask é um micro-framework Python minimalista que simplifica o desenvolvimento rápido de webservices RESTful. Caracterizado pela simplicidade e leveza, o Flask oferece apenas as funcionalidades essenciais para definir rotas e

métodos HTTP, tratar pedidos e formatar respostas, permitindo que programadores construam APIs rapidamente sem sobrecargas desnecessárias [Grinberg, 2018]. Dada a sua integração direta com Python, é uma excelente escolha para projetos que procuram exposição simples e direta de resultados produzidos por pipelines complexos de processamento de dados.

3.3 Abordagem

Foram identificados quatro desafios principais:

1. **Tratar os dados dos datasets:** extrair apenas a informação relevante e torná-la linguística e semanticamente uniforme;
2. **Simular a base de dados da BARTER:** converter ficheiros .csv em tabelas SQL, de forma a ser possível manipular a informação de acordo com as necessidades do sistema;
3. **Codificar informações relativas a deals e creators:** escolher uma representação que preservasse o significado do texto;
4. **Calcular similaridade entre deals e creators:** selecionar um motor de pesquisa vetorial;

3.3.1 Tratamento dos Dados dos Datasets

Foram fornecidos pela BARTER dois datasets, um de deals e um de creators, que apesar de anonimizados, disponibilizam múltiplas informações. O dataset de deals inclui informações como id, referência para o partner que o criou, localização, título e descrição, coordenadas geográficas, timestamps de criação e atualização, morada e país de origem. O dataset de creators inclui id, a sua classificação, descrição, data de criação da conta, género e país de origem, entre outras. Considerou-se que, para desenvolver uma solução para o problema que nos foi proposto, não seria necessário utilizar todas estas informações. Optou-se por:

- **Deals:** manter apenas id, title e description;
- **Creators:** manter apenas id e description.

Após a análise dos vários campos dos datasets filtrados, observou-se a presença de textos que incluíam caracteres indesejados (ex: emojis). Procedeu-se então à substituição de quebras de linha por espaços simples e à remoção de quaisquer caracteres que não fossem letras latinas e de espaços em branco excessivos. O resultado é um texto limpo e otimizado, apenas composto por caracteres alfabéticos e espaços simples.

Verificou-se também que a informação se encontrava escrita em dois idiomas diferentes: inglês e neerlandês. Tendo em conta esta observação, surgiu a necessidade de uniformizar linguisticamente o texto, para facilitar uma posterior compreensão dos resultados. Perante este problema, foram concebidas duas possíveis soluções:

- **Solução 1:** uniformizar os textos antes da simulação da base de dados da BARTER, codificando as informações de deals e creators com os textos em inglês;
- **Solução 2:** codificar as informações de deals e creators com os textos originais, realizando as traduções apenas para apresentação e análise de resultados.


Solução	Prós	Contras
1	• Não há introdução de latência no sistema • Processo realizado uma só vez • Possibilidade de utilização de um modelo mais leve (<code>nomic-embed-text:v1.5</code>)	• Possível perda de significado • Implica pré-processamento moroso
2	• Preservação de significado	• Introdução de latência significativa • Necessidade de utilização de um modelo mais pesado (<code>nomic-embed-text:v2</code>) • Processo realizado sempre que são apresentados resultados

Tabela 3.1: Comparação entre duas Soluções para o Tratamento de Dados.

Avaliados os prós e contras de ambas as soluções, concluiu-se que, apesar da ligeira perda de significado inerente à solução 1, a solução 2 não estava em

conformidade com os requisitos do sistema, pois introduziria excessiva latência em tempo de execução.

Foram conduzidos testes à tradução de descrições através do script `test_translation.py`, que revelaram que, para uma só tradução, podiam ser atingidos tempos de processamento na ordem dos 9 segundos. Tendo em conta que o objetivo é mostrar múltiplos resultados, contendo obrigatoriamente as descrições do creator e dos deals para comparação, introduzir este processamento em tempo de execução tornaria a aplicação excessivamente lenta.



```
Microsoft Windows [Version 10.0.26100.4652]
(c) Microsoft Corporation. All rights reserved.

C:\Users\rgouv>cd C:\ISEL\semestre6\Projeto\Projeto\Implementacao\Limpeza_Filtragem

C:\ISEL\semestre6\Projeto\Projeto\Implementacao\Limpeza_Filtragem>python test_translation.py
A tradução de uma descrição demorou 8.990659952163696 s.
model='thinkverse/towerinstruct' created_at='2025-07-20T18:48:09.7567673Z' done=True done_reason='stop' total_duration=8
984999700 load_duration=11271600 prompt_eval_count=91 prompt_eval_duration=202734000 eval_count=46 eval_duration=8769169
700 message=Message(role='assistant', content=' I am a nutritionist with years of experience from various collaboration
projects. It creates a warm feeling within me when designing healthy, tasty recipes and editing customized photographs o
f my dishes!', images=None, tool_calls=None)

C:\ISEL\semestre6\Projeto\Projeto\Implementacao\Limpeza_Filtragem>
```

Figura 3.2: Testes de Tradução

3.3.2 Simulação da Base de Dados da BARTER

Para aproximar o mais possível o ambiente académico do ambiente real da startup, importaram-se os ficheiros .csv para o MySQL Workbench, criando duas tabelas:

- Creators(id INT PK, description TEXT);
- Deals(id INT PK, title VARCHAR(255), description TEXT).

Esta base de dados local permite realizar operações CRUD idênticas às que o sistema executa, assegurando a sua integridade e possibilitando a realização de testes.

3.3.3 Codificação das Informações de Deals e Creators

Para transformar descrições textuais em representações numéricas comparáveis, consideraram-se duas abordagens: TF-IDF e embeddings produzidos por um LLM. A decisão final exigiu ponderar os requisitos funcionais e não funcionais.

No caso de se utilizar TF-IDF, seria necessário criar um vocabulário a partir de todas as descrições, gerar uma matriz esparsa e aplicar a distância de cosseno para medir proximidade entre creators e deals. No entanto, esta técnica opera ao nível de palavras isoladas, não capta sinónimos nem contexto semântico, o que levaria a recomendações menos robustas.

Ao utilizar embeddings gerados via LLM, cada texto é enviado, após limpeza e tradução, a um modelo exposto localmente pelo Ollama. O vetor é devolvido sem necessidade de fases de treino ou ajuste. Esta abordagem apresenta múltiplas vantagens que influenciaram a escolha decisiva:

1. **Semântica:** o LLM incorpora contexto, sinónimos e relações entre frases, produzindo vetores que distinguem pormenores.
2. **Treino Local:** elimina a necessidade de treinar modelos próprios, qualquer melhoria do LLM é obtida pela sua simples atualização.
3. **Simplicidade operacional:** novos deals entram no sistema e, em segundos, é gerado o seu embedding, tudo sem intervenção manual.

Deste modo, embora TF-IDF fosse uma opção viável, apenas a solução baseada em embeddings satisfaz as exigências do sistema, tornado-a a escolha mais adequada para este contexto.

3.3.4 Cálculo de Similaridade entre Deals e Creators

Após a representação numérica de deals e creators, foi necessário encontrar uma solução para pesquisar, para cada creator, os dez deals mais próximos entre milhares de vetores. Para este efeito, analisámos duas possibilidades: a pesquisa exaustiva e FAISS.

Na pesquisa exaustiva, o sistema compara o vetor de consulta (embedding do creator) com todos os vetores armazenados (embeddings dos deals). O procedimento pode ser descrito concetualmente em três passos:

1. **Carregamento dos vetores:** todos os embeddings de deals são mantidos numa matriz $n \times d$, onde n é o número total de deals e d a dimensão do vetor.
2. **Cálculo de distâncias:** para cada consulta q calcula-se uma distância (cosseno, distância Euclidiana, produto interno) entre q e cada linha da matriz.

3. **Ordenação:** os n valores obtidos são ordenados, dos quais se selecionam os 10 menores.

Em contextos dinâmicos onde é esperada a utilização de uma grande quantidade de vetores, o tempo de resposta cresce linearmente e torna-se impraticável. Embora a pesquisa exaustiva cumpra os requisitos funcionais, os requisitos não funcionais do projeto tornam-na inviável.

Comparativamente, a adoção do FAISS traz um conjunto de vantagens que o tornam particularmente atrativo para sistemas que precisam de pesquisar vetores de alta dimensão de forma rápida e fiável. Destaca-se pelo seu desempenho escalável, graças a estruturas aproximadas como HNSW e IVF, o tempo de resposta mantém-se baixo mesmo quando o número de vetores cresce, permitindo oferecer recomendações quase instantâneas. Esse ganho de velocidade não compromete a qualidade, pois o FAISS alcança taxas de precisão muito próximas da pesquisa exaustiva. A simplicidade de integração é outro benefício central, bastam poucas instruções para criar o índice e efetuar pesquisas, tudo a partir de Python, sem recorrer a serviços externos pagos nem introduzir camadas de complexidade adicionais. Esta independência elimina latências de rede e assegura que os dados sensíveis permanecem dentro da infraestrutura controlada pela equipa. Deste modo, estes fatores fazem do FAISS uma solução robusta e facilmente escalável para este sistema, que depende de pesquisas vetoriais de elevada performance.

Capítulo 4

Implementação do Modelo

Neste capítulo iremos pormenorizar como o modelo proposto no Capítulo 3 foi concretamente materializado em componentes de software e webservice. Começaremos por apresentar a solução adotada para o tratamento de dados, seguida de uma visão geral da arquitetura implementada e da explicação de cada módulo individualmente — desde a persistência em SQL e a geração de embeddings, até à construção e atualização da lista ordenada de deals para cada creator — ilustrando o fluxo de dados. Por fim, explicaremos como esses módulos foram disponibilizados por meio de endpoints REST em Flask e como a interface web foi desenvolvida para facilitar testes e visualização dos resultados, preparando o terreno para a avaliação de desempenho no capítulo seguinte.

4.1 Módulo de Tratamento dos Dados dos Datasets

Uma das primeiras etapas do projeto consistiu em transformar os datasets originais de *deals* e *creators* fornecidos pela BARTER, compostos por várias colunas, textos repletos de caracteres estranhos e descrições escritas em dois idiomas diferentes (inglês e neerlandês). Este processo foi dividido em quatro módulos: `deals_filter.py`, `creators_filter.py`, `deals_cleaner.py` e `creators_cleaner.py`.

No módulo `deals_filter.py`, é carregado o dataset original de deals com recurso ao método `read_csv()` da biblioteca `Pandas`. São extraídas as colunas `id`, `title` e `description`, e o resultado é guardado num novo ficheiro `.csv`. No módulo `creators_filter.py`, o processo é idêntico, mas aplicado ao dataset original de creators, de onde são extraídas as colunas `id` e `description`.




Figura 4.1: Processo de filtragem dos datasets originais

No módulo `deals_cleaner.py` encontram-se duas funções principais: `clean_text()` e `translate()`. A primeira recebe um texto, remove quebras de linha, aplica uma expressão regular que mantém apenas caracteres latinos (substituindo os restantes por espaços em branco) e, por fim, elimina espaços em branco excessivos. A função `translate()` utiliza a API local do Ollama, invocando o modelo `thinkverse/towerinstruct`. Com o texto recebido como parâmetro, é construído um *prompt* que solicita uma tradução ao modelo, que, após ser obtida, é retornada. Para cada título e descrição, ambas as funções são aplicadas, substituindo os textos originais pelos textos limpos e traduzidos, que são posteriormente guardados num novo dataset final. A implementação do módulo `creators_cleaner.py` é bastante semelhante, sendo aplicada exclusivamente às descrições dos creators.




Figura 4.2: Processo de limpeza e tradução dos textos dos datasets

4.2 Organização Modular e Arquitetura MVC




Figura 4.3: Arquitetura geral do sistema.

Optámos por estruturar o nosso projeto seguindo o padrão de arquitetura de software Model-View-Controller, garantindo uma separação clara de responsabilidades e facilitando futuras expansões e manutenções. Dividimos a implementação em três packages principais: webservice, model e barter.

O package webservice representa a componente View do padrão MVC, contendo a aplicação Flask, as rotas (endpoints REST) e toda a interface HTML/CSS para interação com o utilizador final. Esta camada é responsável apenas pela apresentação e recolha de informação, comunicando sempre através do formato JSON.

Dentro do webservice, criámos um sub-package controllers, que inclui dois controllers principais: **StartupController** e **SystemController**. Estes controllers constituem o elo de ligação entre a interface web (view) e a lógica de negócio (model), recebendo pedidos da interface, traduzindo-os em chamadas ao modelo e devolvendo resultados estruturados ao front-end.

O package model centraliza toda a lógica interna do sistema, incluindo operações como a criação e gestão de embeddings, consultas ao índice FAISS e todas as funcionalidades associadas à personalização dos deals para os criadores de conteúdo. Esta camada é completamente independente da interface web e da gestão direta da base de dados, comunicando apenas através dos controllers.

Por fim, decidimos externalizar completamente as operações de acesso à base de dados no package barter, simulando a integração direta com os serviços da empresa parceira. Este package gere exclusivamente as leituras e escritas de dados na base de dados simulada da BARTER, assegurando que a integração seja transparente e facilmente substituível no futuro por uma ligação direta com os sistemas reais da empresa.

4.3 Estrutura e Funcionamento do Webservice

O package webservice foi estruturado de modo a garantir uma implementação clara e organizada das funcionalidades que compõem a camada de apresentação e comunicação do sistema.




Figura 4.4: Estrutura do Webservice

Neste package, encontra-se a aplicação Flask, criada através da função `create_app()`, onde é instanciado o objeto da app e inicializadas as dependências necessárias para o funcionamento do sistema.

Dentro da criação da aplicação Flask, inicializou-se uma instância de **SystemManager**, que atua como fachada para o modelo, disponibilizando métodos que abstraem toda a lógica interna do sistema. O **SystemManager** é passado como dependência para os dois controllers definidos no sub-package controllers: o **SystemController**, responsável pelas operações relacionadas diretamente com deals e rankings, e o **StartupController**, responsável por inicializar o sistema na sua fase inicial, obtendo e preparando todos os dados necessários.

Os controllers desempenham o papel intermédio entre o webservice e o modelo, recebendo os pedidos HTTP encaminhados pelas rotas e invocando operações específicas disponibilizadas pelos **SystemManager**. Por exemplo, quando recebemos um pedido HTTP POST na rota `/deal`, o método `add_deal()` do **SystemController** é acionado. Este, por sua vez, invoca o método correspondente do **SystemManager**, que realiza as operações necessárias no modelo para adicionar um novo deal e atualizar os embeddings e rankings associados.

4.3.1 Rotas

As rotas HTTP são definidas claramente na classe **Routes**, onde estão mapeados os endpoints correspondentes às principais funcionalidades da aplicação:

- GET `/deal/rank/<creator_id>`: retorna uma lista JSON com os deals ordenados por similaridade relativamente ao creator indicado;
- POST `/deal`: adiciona um novo deal através dos dados recebidos num payload JSON;
- PUT `/deal`: atualiza um deal existente através dos dados fornecidos num payload JSON;
- DELETE `/deal/<deal_id>`: remove um deal com o ID especificado;
- POST `/api/startup`: inicializa o sistema obtendo os dados necessários da base de dados simulada da empresa BARTER e calcula os embeddings e rankings.

Adicionalmente, é disponibilizada uma rota padrão na raiz (`/`), que retorna a interface web HTML principal.

Os controllers devolvem sempre respostas padronizadas, compostas por um JSON e um código HTTP adequado, facilitando a comunicação estruturada com a interface e permitindo uma integração clara e direta com o front-end desenvolvido em HTML e CSS.

4.4 Estrutura e Funcionamento do Modelo

O package model constitui o núcleo central da aplicação, reunindo toda a lógica interna que garante a correta execução das funcionalidades relacionadas com deals, criadores e rankings. Neste package, duas classes chave desempenham um papel particularmente importante: `SystemManager` e `StartupManager`.




Figura 4.5: SystemManager e StartupManager

4.4.1 Classe SystemManager

A classe **SystemManager** funciona como fachada ou ponto de entrada principal para todas as operações internas do modelo. Ela coordena diferentes componentes especializados, nomeadamente o **EmbedManager** (gestão de embeddings), o **CreatorManager** (gestão de criadores) e o **DealManager** (gestão de deals).

As operações disponibilizadas pelo **SystemManager** incluem:

- **start()**: invocada na fase inicial do sistema através do **StartupManager**, esta operação obtém todos os dados necessários (deals e criadores), gera embeddings correspondentes e cria o índice de similaridade para gerar rankings personalizados dos deals para os criadores;
- **add_deal()**: recebe um novo deal e adiciona-o ao sistema. Após o sucesso desta operação, atualiza os embeddings e recalcula os rankings;

- `remove_deal(deal_id)`: elimina um deal existente do sistema, e caso a operação seja bem sucedida remove o respectivo embedding e recalcula o índice e os rankings;
- `update_deal(deal)`: permite modificar os dados de um deal já existente, atualizando os embeddings e rankings após uma alteração bem sucedida;
- `get_deal_rank(creator_id)`: consulta e devolve a lista ordenada dos deals mais semelhantes para um criador específico, juntamente com informação relevante;
- `get_deal_by_id()` e `get_creator_by_id()`: permitem obter diretamente objetos `Deal` e `Creator` através dos seus identificadores únicos.

Internamente, estas operações acionam diretamente os métodos correspondentes dos seus componentes especializados (`EmbedManager`, `DealManager` e `CreatorManager`), garantindo uma total abstração e encapsulamento da lógica complexa associada à gestão e atualização de embeddings e rankings.

4.4.2 Classe `StartupManager`

Por sua vez, a classe `StartupManager` é um componente especializado que atua exclusivamente durante a inicialização do sistema. Esta inicialização é necessária para preparar o sistema antes de qualquer pedido proveniente do webservice, com o objetivo de criar todas as estruturas internas incluindo os rankings de deals para cada creator. Desta forma, o sistema fica pronto para apresentar os resultados de forma imediata ao utilizador.

A responsabilidade central desta classe consiste em três tarefas principais:

- `get_deals_from_barter()`: obtém e carrega os deals disponibilizados pela base de dados simulada da empresa BARTER;
- `get_creators_from_barter()`: de modo análogo obtém os criadores diretamente da mesma fonte;
- `create_embeddings()`: após a obtenção dos dados, esta operação gera embeddings para os deals e creators, utilizando o `EmbedManager`, garantindo que os vetores representativos estejam prontos para serem usados na indexação e ranking de similaridade.

4.4.3 Sub-packages creator e deal

O package model está organizado em sub-packages que representam domínios específicos de informação e funcionalidades. Destes, destacam-se os sub-packages deal e creator, estruturados para gerir respetivamente as propostas de colaboração (deals) e os criadores de conteúdo (creators).




Figura 4.6: Sub-packages Creator e Deal

O sub-package deal inclui duas classes: **Deal** e **DealManager**. A classe **Deal** é uma entidade simples, representada por uma dataclass, que armazena a informação essencial de cada proposta: um identificador único (**id**), um título (**title**) e uma descrição (**description**). A classe inclui ainda um método utilitário **format_prompt()**, que gera uma cadeia de texto para servir de entrada para o modelo de linguagem encarregado de produzir o embedding: o prefixo (“document:”) identifica o tipo de conteúdo, servindo de marcador que ajuda o modelo a distinguir este texto de outros (por exemplo, prompts de creators). Em seguida, o método concatena os atributos do **Deal**.

Por outro lado, o **DealManager** funciona como camada intermédia que gere a comunicação direta com o sistema externo (package barter), delegando as operações de criação, atualização e remoção das propostas diretamente ao **BarterRepo**. Este gestor de deals também permite obter listas de propostas ou uma proposta específica

através do identificador único.

No sub-package creator, a organização inclui três classes: **Creator**, **CreatorRepo** e **CreatorManager**. A classe **Creator** também é uma entidade básica representada por uma dataclass, contendo dois atributos: o identificador (**id**) e uma descrição textual (**description**) associada ao criador. Dispõe, assim como a classe **Deal**, um método utilitário **format_prompt()**, diferindo no prefixo (“search_query:”).

A classe **CreatorRepo** é responsável pela manutenção interna dos rankings personalizados dos criadores. Armazena, em estruturas internas, listas ordenadas de deals e as respectivas distâncias associadas, oferecendo métodos para criar e consultar rankings.

O **CreatorManager** constitui o núcleo do sub-package, coordenando todas as operações importantes relacionadas com os criadores. Comunica com o **BarterRepo** para obter listas de criadores e gere diretamente a criação e consulta dos rankings personalizados de deals. Esta classe apresenta a lógica mais complexa do sistema, nomeadamente a criação de um índice FAISS (utilizando o método **IndexHNSWFlat**) para acelerar a pesquisa por similaridade entre os embeddings de criadores e os embeddings das propostas. Para cada criador, realiza consultas ao índice, obtendo uma lista ordenada com as dez propostas mais semelhantes, que são então guardadas no **CreatorRepo**.

4.4.4 Sub-package Embeddings

O sub-package embeddings do package model é responsável por toda a lógica relacionada com a criação, armazenamento e gestão dos embeddings, que constituem a representação vetorial dos creators e deals. Esta componente é essencial para permitir a comparação por similaridade semântica entre creators e deals, servindo de base para o sistema de ranking.

A estrutura interna deste sub-package inclui várias classes especializadas, cada uma com responsabilidades bem delimitadas.




Figura 4.7: Sub-package Embeddings

A classe **Embedding** é uma entidade simples, definida como dataclass, que encapsula um embedding individual, contendo apenas o identificador associado (**id**), correspondente ao **id** do **Deal** que lhe deu origem, e o vetor de representação (**vector**), armazenado como um array NumPy.

A criação dos embeddings é realizada pela classe **Embedder**, que contém um método para gerar embeddings através de uma lista de objetos, sejam eles deals ou creators, e outro para gerar um embedding de um só deal. O método **generate_deal_embed()** recebe uma instância de **Deal**, gera o seu prompt combinando prefixo, título e descrição e envia-o ao componente **OllamaDAO**, que devolve o vetor numérico. Este vetor é encapsulado num objeto **Embedding**. O método **generate_embeddings()** recebe uma lista de deals ou creators. Consoante o tipo dos objetos dessa lista, chama o método **format_prompt()** da classe correspondente, para cada um dos seus elementos, contruindo uma lista de prompts, posteriormente passada ao método **embed_many()** da classe **OllamaDAO**, que devolve o conjunto de vetores na mesma ordem dos pedidos.

A persistência em memória destes embeddings está a cargo de dois repositórios distintos: **DealEmbedRepo** e **CreatorEmbedRepo**. O **DealEmbedRepo** disponibiliza métodos para armazenar embeddings de deals, além de operações de remoção e

atualização, garantindo que qualquer alteração aos dados de um deal implica uma imediata atualização do seu embedding correspondente. Já o `CreatorEmbedRepo` mantém a lista dos embeddings dos creators, com operações de armazenamento mas sem necessidade de remoção ou atualização.

A classe central deste sub-package é o `EmbedManager`, que atua como ponto de coordenação de todas estas operações. O `EmbedManager` contém instâncias de `Embedder` e dos repositórios de embeddings e oferece métodos de mais alto nível como `create_deal_embed()` e `create_creator_embed()`, que geram e armazenam os embeddings. Além disso, expõe operações para adicionar, remover ou atualizar embeddings individuais de deals, e métodos de acesso como `get_deal_embeddings()` e `get_creator_embeddings()`, que devolvem todas as representações vetoriais armazenadas no sistema.

Por fim, a classe `OllamaDAO` encapsula toda a comunicação com a API do Ollama, servindo de camada de acesso aos modelos de embeddings. De modo a evitar a duplicação de código e facilitar a manutenção, definiu-se um atributo `_DEFAULT_MODEL`, cujo valor indica a versão do modelo que se pretende utilizar por defeito.

O método `embed_one()` trata do caso unitário: recebe uma prompt e opcionalmente o nome de um modelo. Se o modelo não for indicado, recorre ao valor predefinido. Extraído o vetor, este é convertido num array `NumPy`. De seguida, é feita a normalização do vetor, eliminando discrepâncias de escala e tornando o produto interno equivalente à distância cosseno.

Para processar vários textos de uma só vez, o método `embed_many()` recebe uma lista de prompts. O fluxo é análogo, determina o modelo, invoca `ollama.embed()` passando a lista completa e espera receber o conjunto de vetores. Estes vetores são convertidos num array `NumPy` bidimensional e, tal como no caso unitário, cada linha é normalizada individualmente. Esta abordagem não só reduz a latência total, ao agrupar múltiplas requisições numa única chamada à API, como também mantém a coerência de escala entre todos os vetores gerados.

4.5 Estrutura e Funcionamento da Base de Dados Simulada

O package `barter` foi concebido para isolar todas as operações de acesso e persistência de dados relacionadas com a base de dados MySQL da aplicação. Esta

camada de abstração permite que o resto do sistema se mantenha independente de detalhes de conectividade e formato dos dados, seguindo princípios de separação de responsabilidades e facilitando futuras alterações ao motor de base de dados ou à forma de armazenamento.




Figura 4.8: Estrutura da Base de Dados Simulada

A classe central deste package é o **BarterRepo**, que atua como repositório e ponto de entrada principal para todas as interações com os dados persistidos. Ao instanciar-se, cria listas internas de deals e creators, além de inicializar um objeto **MySQLDAO**, responsável pelo acesso direto à base de dados. O método **build_deals_list()** executa a consulta de todos os deals existentes na base de dados, através do método **select_deals_from_db()** do **MySQLDAO**, e converte os resultados brutos num conjunto de objetos **Deal** recorrendo à classe **MySQLParser**. Este processo permite construir em memória a lista atualizada de deals. O mesmo processo ocorre em **build_creators_list()**, que recupera e converte todos os creators.

As operações CRUD relacionadas com os deals estão encapsuladas em métodos próprios:

- **add_deal(deal)**: verifica se o deal já existe, se não adiciona-o à lista interna e invoca **add_deal_to_db()** para persistir na base de dados;
- **remove_deal(deal_id)**: elimina um deal existente, atualizando tanto a lista em memória como o registo na base de dados;

- `update_deal(deal)`: atualiza os dados de um deal, tanto localmente como na base de dados, através do método `update_deal_in_db()`.

A classe `MySQLDAO` centraliza todas as interações com a base de dados MySQL, incluindo métodos para estabelecer a ligação (`connect_to_db()`) e executar queries de seleção, inserção, remoção e atualização de dados. Cada método estabelece conexão, executa a operação pretendida e fecha a ligação de forma segura, tratando exceções e garantindo que recursos são libertados mesmo em caso de erro.

Por sua vez, a classe `MySQLParser` é responsável pela conversão de dados brutos (listas de dicionários devolvidas pelo cursor MySQL) em objetos do domínio da aplicação, nomeadamente instâncias das classes `Deal` e `Creator`. Esta etapa é importante para garantir que toda a aplicação manipula apenas instâncias de classes bem definidas e não estruturas de dados genéricas.

4.6 Interface Web

A interface web do projeto foi contruída através de uma página HTML única. Toda a interação com o back-end é feita através de JavaScript usando a `FetchAPI`. O endereço base da API é parametrizado na constante `API_BASE`, permitindo alojar o mesmo front-end em qualquer ambiente sem modificação de código. A página organiza-se em funcionalidades: as quatro primeiras secções apresentadas dizem respeito ao Startup e às operações CRUD sobre os deals (adicionar, remover e atualizar). Finalmente, apresenta-se uma secção que permite obter o ranking personalizado de um creator. Cada botão invoca uma função que envia o pedido HTTP correspondente com o método apropriado. As respostas do servidor são capturadas, convertidas em JSON e impressas numa consola de forma a dar feedback imediato ao utilizador. Para apresentar os resultados do ranking, a função `showDealRank()`, contrói dinamicamente uma tabela: insere o id e a descrição do creator e, para cada deal pertencente ao rank desse creator, gera uma linha da tabela com id, título, descrição e distância.

The image displays a wireframe for a web application titled "DEAL RANK". The interface is set against a dark blue background. At the top center, there is a logo consisting of a green square with a white letter 'B' inside, followed by the text "DEAL RANK" in a large, bold, light green sans-serif font. Below the header, the application is divided into four main functional areas, each represented by a light blue rectangular panel. 1. The "Startup" panel on the top left contains a title "Startup" in bold green text, a dark blue button labeled "Run Startup", and a "Console" section with a single white input field. 2. The "Add Deal" panel on the top middle contains a title "Add Deal" in bold green text, three white input fields labeled "Deal ID", "Title", and "Description", a dark blue button labeled "Add Deal", and a "Console" section with a single white input field. 3. The "Remove Deal" panel on the top right contains a title "Remove Deal" in bold green text, a single white input field labeled "Deal ID", a dark blue button labeled "Remove", and a "Console" section with a single white input field. 4. The "Update Deal" panel on the bottom right contains a title "Update Deal" in bold green text, three white input fields labeled "Deal ID", "Title", and "Description", a dark blue button labeled "Update", and a "Console" section with a single white input field. At the bottom of the interface, there is a wide, light blue panel. It starts with a title "Get Deal Rank" in bold green text, followed by a long white input field labeled "Creator ID". Below this is a dark blue button labeled "Get Rank", and at the very bottom, another "Console" section with a long white input field.

Figura 4.9: Interface sem Resultados

Get Deal Rank

Create ID

Get Rank

Console

Create ID: 1

Create Description: Explores new restaurants five days a week, filming detailed reviews of menus, plating, and ambience for her YouTube and Instagram channels. Posts step-by-step tasting notes on Italian classics—from regional pasta flights to wood-fired pizzas—and rates each spot on authenticity, ingredient quality, and value. Hosts live "look-along" streams where viewers follow her through multi-course meals, uploads short recipe recollections of standout dishes, and curates a monthly map of must-try trattorias and gelaterias for her newsletter.

ID	Description	Distance
1	Regional Pasta Flights Review Series with Pacifico Classico	0.41534504
9	Authenticity Audit Tour with Tuscany Food Trails	0.5339165
6	Wood-Fired Pizza Challenge with Vero Formo	0.57040405
1532	Dinner at the Seaford Bar Years	0.6889983
3470	Restaurant Johannes dinner for	0.69006036
3086	Sip Paint Pizza Pollo Gelato	0.6964747
3480	How to make the best chicken nuggets	0.70753866
3271	Get bottles of Purely Homemade Hot Sauce	0.7148641
3483	Wine Food Pairing Taste Notes Grape N Green	0.7183449
1539	Tiptoland Promotion FOR GERMAN INFLUENCERS	0.7239735

Figura 4.10: Interface com Apresentação de Resultados

Capítulo 5

Validação e Testes

5.1 Objetivo da Validação

O principal objetivo deste capítulo é demonstrar que o sistema desenvolvido consegue gerar recomendações personalizadas e coerentes de propostas de colaboração (deals) para cada criador de conteúdo registrado na plataforma. Uma vez que não nos foram disponibilizados dados históricos reais que permitissem comparar resultados, optámos por recorrer a dados sintéticos criados especificamente para esta fase, garantindo assim a possibilidade de observar e avaliar o comportamento do algoritmo de ranking em diferentes cenários simulados.

5.2 Dados de Teste Utilizados

Para realizar validação, criámos quatro criadores de conteúdo e doze propostas de colaboração que cobrem perfis distintos, como gastronomia, moda, desporto e gaming. Cada criador foi descrito através de um texto detalhado que reflete o seu domínio de atuação e estilo de criação de conteúdos. As propostas de colaboração foram igualmente elaboradas para representar diferentes tipos de campanhas, desde restaurantes e produtos de moda até campanhas de desporto, bem-estar e produtos tecnológicos. Estes dados sintéticos permitiram criar um ambiente de teste suficientemente diversificado para validar se o sistema conseguia diferenciar corretamente as descrições e gerar rankings coerentes e consistentes.

5.2.1 Creators

ID	Description
1	Explores new restaurants five days a week, filming detailed reviews of menus, plating, and ambience for her YouTube and Instagram channels. Posts step-by-step tasting notes on Italian classics—from regional pasta flights to wood-fired pizzas—and rates each spot on authenticity, ingredient quality, and value. Hosts live “fork-along” streams where viewers follow her through multi-course meals, uploads short recipe recreations of standout dishes, and curates a monthly map of must-try trattorias and gelaterias for her newsletter.
4	Energetic and driven, this sports-focused creator brings the discipline of an athlete and the spontaneity of an adventurer. As a professional volleyball player and coach, he blends training insights with motivational content and behind-the-scenes moments from his athletic journey. Off the court, he’s a thrill-seeker who’s always chasing his next outdoor adventure or forging meaningful partnerships. His content reflects teamwork, resilience, and a love for pushing limits—both physically and creatively.
5	Stylish, confident, and effortlessly chic, this creator lives and breathes fashion. She curates stunning outfits, beauty tutorials, and brand collaborations that reflect her eye for detail and trend-savvy sensibility. Whether she’s unboxing new collections or sharing her daily routines, her aesthetic is polished yet approachable. With a loyal following, she’s become a trusted voice in the beauty and fashion space—always inspiring others to express themselves through style.
7	Playful, witty, and endlessly charismatic, this creator thrives in the world of live streaming. With a quick sense of humor and a passion for gaming, she’s known for turning even the most intense matches into moments of laughter. Whether she’s battling bosses or bantering with her chat, her streams feel like hanging out with a close friend. Outside the virtual world, she’s a lover of memes, pop culture, and all things geeky, always keeping her community entertained and connected.

Tabela 5.1: Descrições sintéticas dos creators de teste

5.2.2 Deals

ID	Title	Description
1	Regional Pasta Flights Review Series with Pastificio Classico	Pastificio Classico, an artisanal producer from Emilia-Romagna, ships a regional pasta flight to you every week and reserves tables at new restaurants that feature their specials. You film detailed reviews of each venue's menus, plating, and ambience for your YouTube and Instagram channels, then post step-by-step tasting notes rating authenticity, ingredient quality, and value.
2	Serve & Spike – Athletic Gear Collaboration	Join forces with our high-performance sportswear brand to spotlight our newest volleyball line. Post in-action reels, gear reviews, or training tips while wearing our apparel. Get exclusive gear, commission bonuses, and discount codes for your community.
3	Glow Routine – Skincare Kit Launch	We're launching a new line of glow-boosting skincare and looking for beauty-forward creators to share honest reviews and tutorials. Receive a full PR package and be featured on our socials as a skincare ambassador.
4	AdventureFuel – Energy Drink Campaign	Collaborate with our bold new energy drink brand. We're looking for energetic creators to post challenge content, lifestyle reels, or shoutouts featuring our drinks. Includes free product, campaign bonuses, and paid features.
5	City Streets – Urban Streetwear Drop	We're launching a limited-edition urban wear collection inspired by city culture. We're looking for creators with strong style to post photo sets, fashion reels, and styling tips. Includes free items, reposts, and potential capsule collection design.

(continua na próxima página)

(continuação)		
ID	Title	Description
6	Wood-Fired Pizza Challenge with Vero Forno	Vero Forno provides a countertop wood-pellet oven and ingredient kits. You host live fork-along streams where viewers follow your bake-off of three classic wood-fired pizzas, turned into a mini multi-course meal. Between streams you upload step-by-step tasting notes and a short recipe recreation reel for each pie.
7	ProCoach – Online Training App Feature	Become an ambassador for our new coaching platform for athletes. You'll receive a free premium membership and the chance to monetize your coaching tips and workouts via in-app content and social shoutouts.
8	LuxeLens – Fashion Sunglasses Drop	Be the face of our upcoming luxury sunglasses line. We're offering product gifting and paid social content campaigns. Looking for fashion-savvy creators who can showcase unique styling with our exclusive eyewear.
9	Authenticity Audit Tour with Tuscany Food Trails	Tuscany Food Trails sponsors a five-day itinerary where you explore new restaurants—from family-run trattorias to hidden-gem gelaterias—filming detailed reviews every day. Content focuses on Italian classics such as risotto, bistecca alla fiorentina, and regional desserts.
10	Level Up Lounge – Gaming Chair Sponsorship	Partner with our premium ergonomic gaming chair brand and showcase comfort and performance in your stream setup. We're offering a free chair and affiliate bonuses in exchange for authentic shoutouts and a dedicated unboxing video.
11	StreamBeats – Royalty-Free Music Promo	Help us promote our royalty-free music platform for creators. We're offering free access to our full library and paid partnerships in exchange for behind-the-scenes content showing how you use our tracks in streams, videos, or edits.
(continua na próxima página)		

(continuação)		
ID	Title	Description
12	CozyKit – Custom Stream Overlay Bundle	We're releasing a line of customizable stream overlays and alerts. We want content creators to show them in action and share their unique setup aesthetics. Get free bundles and earn via referral links.

Tabela 5.2: Descrições sintéticas dos deals de teste

5.3 Metodologia de Teste

Os testes seguiram os seguintes passos:

1. Inserção dos Dados:

- **Creators:** foram registados diretamente na base de dados MySQL através de um script SQL;
- **Deals:** foram introduzidos utilizando a própria aplicação, recorrendo ao endpoint POST `/deal` exposto na interface Add Deal.

2. **Inicialização do Sistema:** Depois de todos os registos inseridos, executou-se o endpoint POST `/api/startup`, responsável por gerar os embeddings de creators e deals e construir o índice FAISS utilizado para a pesquisa por similaridade.

3. **Consulta dos Rankings:** Na interface gráfica, na secção Get Deal Rank, introduziu-se o id de cada creator e submeteu-se o pedido. O sistema devolveu uma tabela com os dez deals mais semelhantes, mostrando para cada um o identificador único, o título, a descrição e a distância entre o vetor do deal e o vetor do creator, permitindo avaliar visualmente a pertinência das recomendações.

5.4 Critérios de Validação

Para validar os testes conduzidos, definiram-se os seguintes critérios:

- O sistema devolve exatamente dez deals por creator;

- Os deals encontram-se ordenados por ordem crescente de distância, ou seja, os primeiros deals do rank são os mais semelhantes;
- As descrições dos deals mais próximos devem estar alinhadas com a descrição do creator.

5.5 Resultados Obtidos

5.5.1 Resultados para o Creator 1

Descrição do Creator: Explores new restaurants five days a week, filming detailed reviews of menus, plating, and ambience for her YouTube and Instagram channels. Posts step-by-step tasting notes on Italian classics— from regional pasta flights to wood-fired pizzas— and rates each spot on authenticity, ingredient quality, and value. Hosts live “fork-along” streams where viewers follow her through multi-course meals, uploads short recipe recreations of standout dishes, and curates a monthly map of must-try trattorias and gelaterias for her newsletter.

Ao consultar o ranking para este creator, obteve-se a seguinte lista de deals ordenados:

ID	Title	Description	Distance
1	Regional Pasta Flights Review Series with Pastificio Classico	Pastificio Classico, an artisanal producer from Emilia-Romagna, ships a regional pasta flight to you every week and reserves tables at new restaurants that feature their specials. You film detailed reviews of each venue’s menus, plating, and ambience for your YouTube and Instagram channels, then post step-by-step tasting notes rating authenticity, ingredient quality, and value.	0.41534504

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
9	Authenticity Audit Tour with Tuscany Food Trails	Tuscany Food Trails sponsors a five-day itinerary where you explore new restaurants—from family-run trattorias to hidden-gem gelaterias—filming detailed reviews every day. Content focuses on Italian classics such as risotto, bistecca alla fiorentina, and regional desserts.	0.5339165
6	Wood-Fired Pizza Challenge with Vero Forno	Vero Forno provides a counter-top wood-pellet oven and ingredient kits. You host live fork-along streams where viewers follow your bake-off of three classic wood-fired pizzas, turned into a mini multi-course meal. Between streams you upload step-by-step tasting notes and a short recipe recreation reel for each pie.	0.57040405
1532	Dinner at the Seafood Bar years	Get a delicious dinner with a gift card. You can choose everything from the menu. Enjoy the taste of the sea. It is possible we would like to promote the video so we can ask for your spark code. It will be great for your reach as well. We can use your video on our own socials too.	0.6898983

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
3470	Restaurant Johannes dinner for	In exchange for a TikTok and/or Instagram Reel, we offer an Instagram Story and a star review on Google. We provide a set menu for two people at Eet-café Johannes in Breda. The first two drinks per person are free (wine, beer, tea or coffee); everything else is paid by yourself. Additionally, we have a bonus system based on the number of views you obtain with one post, reel or TikTok.	0.69006836
3086	Sip Paint Pizza Pollo Gelato	Saturday February: first edition of Sip Paint at Geniet — enjoy cocktails and finger food while you bring your creative talents to life on a canvas. Includes cocktail or mocktail, finger food platter per person, and all materials to make your artwork. Extra drinks or food at own expense.	0.6964747
3480	How to make the best chicken nuggets	In exchange for a video on Instagram we give you 1kg of chicken nuggets indistinguishable from the famous fast food chain with an “M”. Higher quality; shipped frozen for fryer or airfryer. Make the well-known nuggets with your own twist to ride the gourmet fast-food trend.	0.70753866
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
3271	Get bottles of Purely Homemade Hot Sauce	Short, catchy videos highlighting our Carolina Reaper Chili Sauce: grilled sandwich finish, first reaction (spiciness & taste) or a challenge. You receive bottles of Carolina Reaper, Ghost Pepper and Thai Chili Sauce. Explain why you are the right influencer for this collaboration.	0.7149641
3483	Wine Food Tasty combinations Grape N Green	One bottle (excluding sparkling) matched to a dish (or surprise) + optional discount code. Deliver at least posts/reel showing wine + pairing; explain why it works, tag Grape N Green, create authentic content (possibility to combine multiple deals).	0.7183449
1539	Tippland Promotion FOR GERMAN INFLUENCERS	Promote tippland.de on Instagram / YouTube via review or general test. Tiered earning depends on potential reach (weekly views thresholds). Contact us to discuss details and compensation.	0.7239735

Tabela 5.3: Ranking do Creator 1

5.5.2 Resultados para o Creator 4

Descrição do Creator: Energetic and driven, this sports-focused creator brings the discipline of an athlete and the spontaneity of an adventurer. As a professional volleyball player and coach, he blends training insights with motivational content and behind-the-scenes moments from his athletic journey. Off the court, he's a thrill-seeker who's always chasing his next outdoor adventure or forging meaningful partnerships. His content reflects teamwork, resilience, and a love for pushing limits—both physically and creatively.

Ao consultar o ranking para este creator, obteve-se a seguinte lista de deals ordenados:

ID	Title	Description	Distance
2374	Drink for the sports creator	Do you have a passion for running, cycling or triathlon? Perfect, we are looking for you. Vitalicsport.com is a sports brand aimed at endurance athletes to help them become and stay free of injuries. For our content marketing we seek enthusiastic and sporty creators. Currently we specifically want collaboration around our drink bottle set. Videos do not have to be standard advertisements; we prefer that you use our products to share valuable tips (e.g. how to use a foam roller or effective exercises with a fitness band). Few restrictions on video type—let your creativity run free. You can also provide a percentage discount code to followers so the collaboration benefits them.	0.6649602 —

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
3135	Influencer models wanted – Make fitness lifestyle empowerment posts with our outfits	Discover the unique combination of strength and fashion with Defeat Your Demons. Our brand was born from a passion for empowering people while elevating their style. Fashion is more than clothing: it is expression of inner strength and confidence. We combine self-empowerment messages with trendy designs—textual and “Demon Slayer” motifs—for anyone wanting to feel strong and stylish on and off the sports field. We seek dynamic influencers sharing our vision. As ambassador you receive exclusive pieces in exchange for engaging posts, reels and stories. Share your experience and inspire followers to stand strong with empowering outfits.	0.6690835 —
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
2549	Fitness influencers wanted – show your workouts in our outfits	Discover the blend of strength and fashion with Defeat Your Demons. Born from a passion for empowering people while elevating style. We believe fashion expresses inner strength and confidence. Collection includes inspirational textual designs and iconic Hero designs for those who want to feel strong on and off the sports field. We seek male and female influencers who share this vision. As ambassador you receive exclusive pieces for engaging posts, reels and stories. Inspire your followers to embrace a healthy empowered lifestyle.	0.6801226 —
2145	Sports and health influencers – try Ultimate Electrolytes	Ultimate Electrolytes is a supplement formulated to quickly restore electrolyte levels—ideal for active people needing hydration boost and energy support after heavy exertion. Target: athletes, outdoor enthusiasts or anyone with active lifestyle needing regular recovery. Provides optimal mix of sodium, potassium, magnesium and calcium to aid fluid absorption, reduce cramps, restore energy, promote concentration and prevent fatigue—result: a well hydrated, energized body ready for the next challenge. Ingredients: sodium, potassium, magnesium, calcium, natural flavorings.	0.69551736 —
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
2582	Months of online fitness coaching	Months of online coaching: on-line intake conversation; weekly check-ins; tailored meal plan with dish choices per meal; training plans adapted to needs; explanation and support; full access to GE Fitness Coaching program; supplement advice. Coach Galbin guides customers toward a sustainable healthy lifestyle—nutrition and training plans adapted so users avoid monotonous “chicken and rice” routines. Daily updated meal options via the app. Goal: reach physical and mental improvements sustainably.	0.7426321 —
2373	Fitness tape for sports TikTok creators	Passion for running, cycling or triathlon? Vitalicsport.com targets endurance athletes to help them remain injury-free. We seek sporty creators for collaboration around our fitness tape set. Prefer content using products to share practical tips (foam roller usage, effective elastic band exercises). Few restrictions—creativity encouraged. Provide a percentage discount code so followers benefit.	0.7439239 —

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
2375	Knee brace set for sports creators	Passion for running, cycling or triathlon? Vitalicsport.com supports endurance athletes staying injury-free. We now look for collaboration on our Knee Brace Set. Videos need not be standard ads; prefer demonstrations with practical tips (foam roller, effective elastic exercises). Few restrictions; creativity welcome. Option to give followers a percentage discount code.	0.7440706 —
2	Serve & Spike – Athletic Gear Collaboration	Join forces with our high-performance sportswear brand to spotlight the newest volleyball line. Post in-action reels, gear reviews, or training tips while wearing our apparel. Get exclusive gear, commission bonuses and discount codes for your community.	0.7603135 —
7	ProCoach – Online Training App Feature	Become an ambassador for our new coaching platform for athletes. Receive a free premium membership and the chance to monetize coaching tips and workouts via in-app content and social shoutouts.	0.7622263 —
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
1636	Resistance bands set for fitness TikTok creators	Passion for running, cycling or triathlon? Vitalicsport.com serves endurance athletes aiming to remain injury-free. Collaboration focus: our resistance band set. Prefer instructional content (foam roller usage, effective elastic exercises) rather than pure ads. Few restrictions—creativity encouraged. Provide a percentage discount code benefiting followers.	0.7645287 —

Tabela 5.4: Ranking do Creator 4

5.5.3 Resultados para o Creator 5

Descrição do Creator: Stylish, confident, and effortlessly chic, this creator lives and breathes fashion. She curates stunning outfits, beauty tutorials, and brand collaborations that reflect her eye for detail and trend-savvy sensibility. Whether she’s unboxing new collections or sharing her daily routines, her aesthetic is polished yet approachable. With a loyal following, she’s become a trusted voice in the beauty and fashion space—always inspiring others to express themselves through style.

Ao consultar o ranking para este creator, obteve-se a seguinte lista de deals ordenados:

ID	Title	Description	Distance
3135	Influencer models wanted – Make fitness lifestyle empowerment posts with our outfits	Discover the unique combination of strength and fashion with Defeat Your Demons. Our brand was born from a passion for empowering people while elevating their style at the same time. We believe that fashion is more than just clothing; it's an expression of inner strength and self-confidence. We combine self-empowerment messages with trendy designs (inspirational textual motifs and iconic “Demon Slayer” designs) for anyone who wants to feel strong and stylish on and off the sports field. We seek dynamic influencers (male or female) who share our vision. As ambassador you receive exclusive pieces in exchange for engaging posts, reels and stories. Share your experience, inspire followers, join the movement showing how fashion and empowerment go hand in hand.	0.5817784

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
2549	Fitness influencers wanted – show your workouts in our outfits	Discover the blend of strength and fashion with Defeat Your Demons. Fashion expresses inner strength and confidence. Collection: inspirational textual designs and iconic Hero designs for strength on and off the sports field. We seek male and female influencers sharing this vision. As ambassador you receive exclusive pieces for engaging posts, reels and stories. Inspire followers to embrace a healthy, empowered lifestyle and show how fashion and empowerment go hand in hand.	0.62666225
3692	Putting together Ralph Lauren outfits in showroom photo studio	Point of sale for exclusive authentic Ralph Lauren clothing/accessories. Creator selects outfits (show varied styles: oversized, vintage, etc.) and produces content in a luxury showroom (champagne, comfortable seating) or against a white studio backdrop. In exchange for content and exposure, creator chooses a Ralph Lauren outfit to keep. Aim: mutually valuable collaboration leveraging brand appeal. Visit timelesstreasury.nl for first impression.	0.647115

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
2911	Fashion content creators	We lanceren Basket en zoeken creators zoals jij. (ENGLISH) Meet Basket, platform where fashion and creativity converge. Onboarding hundreds of brands and inviting creators. Steps: create account/profile; create at least three “Baskets” and post one story/photo/video; share profile on social media. Benefits: exclusive Creator Badge (early adopters), collaboration opportunities, vouchers, free shopping, growing community where style makes the difference.	0.6598462
2393	Receive cozy house packages worth	Looking for mom or lifestyle influencer who conveys cozy, warm atmosphere and shares everyday self-care and comfort. Offer: two housecoats (Pastunette collection); one-minute video showing loungewear; high-quality mood photos (sofa, coffee/tea, book) for landing page; discount code for followers. Apply only if able to produce high-quality imagery reflecting relaxed, cozy atmosphere.	0.66437566
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
3382	Hair extensions YOAR MUSE ambassador	Become a YOAR MUSE ambassador. Add volume, length and confidence with premium extensions that enhance style and self-esteem. Looking for creators with strong presence (Instagram, TikTok, YouTube), passion for beauty/haircare, authentic follower connection. Offer: free weft extension set (up to 100 g) applied in partner salon; community membership; potential feature. Share motivation and unleash hidden muse daily.	0.6653841
2978	DEVENTE Brand Promotion	DEVENTE launches stylish stainless steel jewellery (non-tarnish, waterproof, nickel-free) plus versatile clothing. Mission: confidence and beauty in everyday wear. Seeking fashion/lifestyle influencers (macro or micro) with genuine audience connection. Content: fun, honest (unboxing, styling, talking clips) without overly promotional tone. Creative freedom encouraged. Brand may reuse content on socials/ads (tag us). Focus on authenticity and personal styling.	0.669102

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
2958	Elegance Unveiled	GlowCity Rotterdam partnership: curated luxury self-care experience. Possible treatments: BIAB, gel nails, luxe pedicure, brow styling. Perks: personalized top-tier services, early access to new products, feature on social channels/website. Goal: showcase sophistication, elegance and daily luxury—share the experience with audience.	0.6760149
2520	Creative content creators wanted.	L Adele Studios seeks influencers to promote luxury press-on nails. Offer: sets of pre-made handcrafted salon nails for varied looks. Ideal for creators skilled in Instagram content and manicure aesthetics.	0.6813203
3235	Book Your Love Dip	Influencer profile focused on relationships, self-development and mindfulness (micro-influencer with high engagement). Deliverables: Instagram post and/or TikTok video sharing authentic experience with the book plus call to action. Offer: free copy with handwritten note + extra copy for giveaway. Aim: honest storytelling, emotional connection, encouragement to order via link or discount code.	0.6877221

Tabela 5.5: Ranking do Creator 5

5.5.4 Resultados para o Creator 7

Descrição do Creator: Playful, witty, and endlessly charismatic, this creator thrives in the world of live streaming. With a quick sense of humor and a passion for gaming, she's known for turning even the most intense matches into moments of laughter. Whether she's battling bosses or bantering with her chat, her streams feel like hanging out with a close friend. Outside the virtual world, she's a lover of memes, pop culture, and all things geeky, always keeping her community entertained and connected.

Ao consultar o ranking para este creator, obteve-se a seguinte lista de deals ordenados:

ID	Title	Description	Distance
1736	Play drinking games with your friends – influencer board game	We from www.avondmakers.nl are experts in organizing fun evenings with friends. To share this with more people we seek talented creators to make content for our game *Kutfluencers*. It combines fun challenges, cozy assignments and mini-games into a large drinking game. Special feature: boxes with Milo Raoul (De Bankzitters) and cards featuring Stefan de Vries, Bram Krikke and other influencers. Ensure your content is viewed and rewarded: k views euro ... (tiered rewards). Not getting enough views? We use Spark Ads so you can still generate many views days after posting.	0.7514949

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
2596	Play drinking games with your friends – legendary board game	We from www.avondmakers.nl organize fun evenings and seek creators for our new game *Horse Race*. Spectacle guaranteed. You don't like horses? Neither do we—what we like is sharing drinks with friends. A drinking game has never been so exciting. Tiered reward system (k views euro ...). If organic reach is low we use Spark Ads to boost good videos days later.	0.7667811
2206	X-Mas Boost with Pranktastic	Pranktastic seeks enthusiastic TikTok and Instagram influencers to spread holiday cheer with our Prank Cards, especially the *Meowy Christmas* card. Looking for creators who bring humor, playfulness and festive fun. If followers enjoy lighthearted pranks, unique holiday cards and glitter surprises, collaborate with us to make the season memorable.	0.7880409
2875	Make Chef Mallows unbeatable with your content	Creative influencer (minimum follower threshold) who loves inspiring content. *Chef Mallows* focuses on handmade marshmallows—visual storytelling that creates desire, evokes taste, coziness and indulgence. Goal: content that is an eye treat and narrative, transporting followers into an atmospheric world (“I want this too”).	0.7905468
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
3382	Hair extensions YOAR MUSE ambassador	Become a YOAR MUSE ambassador. Passion for beauty and hairstyling? Add volume, length and self-confidence with premium extensions that transform looks and reinforce self-esteem. Seeking creators with strong presence (Instagram, TikTok, YouTube), authentic connection and passion for haircare. Offer: free weft extension set (up to 100 g) in partner salon, community membership, feature opportunities. Unleash your hidden muse daily.	0.7965148
2822	Paid collaboration – capture the smile of a child (Snappaboo)	Get Snappaboo and let creativity run wild. Show how hard it seems to get a child to look and smile at the camera—then demonstrate how opening Snappaboo triggers an instant radiant smile. Share experience and show parents how to capture pure moments forever.	0.80383337
(continua na próxima página)			

(continuação)			
ID	Title	Description	Distance
2967	Allround Content Creator – Fits Kids	Regular posts on Instagram, TikTok, Facebook: original UGC, child-friendly videos, reels, photos, stories. Creative experimentation with D pen and artworks inspiring children and parents. Requirements: experience with creative tools (Canva, CapCut, Adobe), playful energetic style suiting children’s products (bonus if you have children). Offer: ongoing collaboration with growing brand, flexible hours, platform to elevate creativity. Apply via email with intro and portfolio—“Together we make the world more colorful.”	0.80822253
3131	Valentine’s Day prank card	Pranktastic seeks TikTok/Instagram influencers to spread Valentine cheer with prank cards. Looking for humor, playfulness and festive fun. If audience enjoys lighthearted pranks, unique themed cards and glitter surprises, collaborate with us to make this Valentine unforgettable.	0.8142972
2821	Paid collaboration – capture the smile (Snappaboo variant)	Get Snappaboo and show how difficult it is to get a child to look and smile; with Snappaboo the smile appears instantly. Share authentic experience and demonstrate how parents can preserve these pure moments.	0.8145678

(continua na próxima página)

(continuação)			
ID	Title	Description	Distance
3362	Breathe Better, Create Better – Breathbuddi UGC Creator	Breathbuddi focuses on well-being through breathing: advanced nose strips and mouth tape (durable during intense workouts). Seeking healthy, active, authentic creators focused on well-being, sport and sleep optimization. Content: photos (daily life, sport, bed, before/after) and videos showing improved breathing, focus, sleep quality, reduced stress. Emphasize ease of use, strong adhesion, performance improvements and daily applicability.	0.81797177

Tabela 5.6: Ranking do Creator 7

5.6 Discussão dos Resultados

Os testes com dados sintéticos mostraram que o algoritmo de recomendação cumpriu os três critérios definidos na secção 5.4 nos casos dos creators 1, 4 e 5. No entanto, os resultados para o creator 7 mostraram-se menos coerentes em termos do conteúdo dos deals sugeridos.

5.6.1 Coerência Temática

- Para o Creator 1 (foco em gastronomia italiana), os três primeiros deals tratam, respetivamente, de degustações de diversos pratos de massa, itinerários de restauração toscana e desafios de pizza em forno de lenha, todos estes tópicos são explicitamente mencionados na descrição do creator;
- No caso do Creator 4 (desporto e treino), as propostas líderes são garrafas desportivas, roupas fitness e colaborações com marcas de suplementação;
- Para o Creator 5 (moda e beleza), os deals melhor posicionados incluem

sessões de styling, parcerias com joalheria ou press-on nails e campanhas “fashion content creators”;

- No caso do Creator 7, fica evidente uma possível lacuna deste sistema. Os dois primeiros deals recomendados baseiam-se em jogos para jogar com amigos, o que se enquadra neste creator. No entanto, os restantes deals revelam estar mais relacionados com a personalidade do creator do que com as suas atividades e interesses, apontando para a possibilidade do embedding deste creator ter sido dominado por palavras menos relevantes para o objetivo da aplicação, indicando que o sistema ainda pode ser refinado.

5.6.2 Distâncias

Em todos os casos, é possível observar um aumento gradual das distâncias, enquanto o conteúdo dos deals se afasta, lentamente, do conteúdo da descrição do creator. De notar que não se observaram “intrusos”, isto é, deals tematicamente incoerentes, inseridos no ranking, com distâncias inferiores às de deals considerados mais corretos. Todos estes pontos são bons indicadores para o correto funcionamento da componente de ordenação do sistema.

Capítulo 6

Conclusões e Trabalho Futuro

Neste projeto foram exploradas técnicas de representação semântica e pesquisa por similaridade no contexto da recomendação personalizada de conteúdos ao utilizador. Com o objetivo de conceber uma solução para a limitação identificada na aplicação móvel da BARTER, foram utilizados embeddings gerados por Large Language Models (LLMs) e pesquisa eficiente através de indexação FAISS, evitando a apresentação das propostas sem qualquer grau de personalização. A solução desenvolvida foi designada por Deal Rank.

O processo de desenvolvimento do Deal Rank consistiu na extração inicial das informações relevantes sobre creators e deals, seguida da geração local dos embeddings, através da ferramenta Ollama. Posteriormente, foram realizadas pesquisas por similaridade utilizando a biblioteca FAISS, permitindo construir rankings personalizados de deals para cada creator.

A utilização do Ollama permitiu gerar todos os embeddings através de uma única chamada à API, diminuindo consideravelmente o consumo de memória RAM e reduzindo a latência global do sistema. Por outro lado, o índice HNSWFlat disponibilizado pelo FAISS revelou-se especialmente vantajoso, permitindo pesquisas por similaridade rápidas e precisas, mesmo com grandes volumes de dados, oferecendo um equilíbrio adequado entre velocidade e qualidade dos resultados obtidos.

Os resultados alcançados através dos testes sintéticos realizados permitiram confirmar o cumprimento do objetivo central do projeto: apresentar ao utilizador uma lista dos dez deals mais semelhantes ao respetivo creator. Através da observação direta, confirmou-se uma clara semelhança semântica entre os conteúdos das descrições dos deals recomendados e as descrições dos creators correspondentes. Além disso, o sistema demonstrou-se especialmente eficiente no processamento

inicial dos dados e na apresentação praticamente imediata dos resultados.

Contudo, a solução implementada apresenta algumas limitações relevantes. Uma vez que a funcionalidade desenvolvida neste projeto ainda não está disponível na aplicação da BARTER, a empresa não dispõe atualmente de dados que possam ser utilizados para contra-validação. Em consequência, não foi possível aferir objetivamente a precisão ou aplicar métricas quantitativas ao desempenho do sistema. A validação efetuada, baseada exclusivamente em testes sintéticos e observação direta dos resultados, implica uma avaliação predominantemente qualitativa e subjetiva.

Outra limitação prende-se ao facto de grande parte das descrições dos creators incluírem traços de personalidade, para além das suas áreas de interesse. Isto origina situações em que o sistema recomenda deals cujo público-alvo corresponde sobretudo a creators com traços de personalidade semelhantes, mesmo que não estejam diretamente alinhados com as áreas específicas de interesse do creator em causa.

A origem desta limitação deve-se à utilização do modelo Nomic-embed-text, que é baseado em transformers. Como referido anteriormente na secção 3.2.6, os modelos baseados em transformers utilizam mecanismos de self-attention, atribuindo pesos específicos às palavras com base na sua relevância contextual. Desta forma, traços de personalidade destacados nas descrições podem assumir um peso indevidamente elevado no processo de comparação, originando recomendações semanticamente corretas, mas contextualmente desajustadas às áreas de interesse específicas dos utilizadores.

Com o objetivo de ultrapassar este desafio, idealizou-se uma possível solução futura que permitiria resultados mais precisos e ajustados aos interesses específicos dos creators. Esta solução consistiria na utilização de um LLM especializado em análise de texto, capaz de filtrar as descrições completas dos creators, extraíndo e devolvendo entre três a cinco palavras-chave que melhor representassem os seus interesses principais. Neste cenário, os embeddings seriam criados diretamente a partir destas palavras-chave, em vez das descrições originais completas. Acredita-se que, desta forma, seria possível reduzir significativamente a influência de traços de personalidade nas recomendações, aumentando assim a relevância e a precisão contextual dos resultados obtidos.

Concluindo, apesar das limitações identificadas e dos desafios enfrentados, considera-se que o projeto cumpriu os objetivos inicialmente definidos, oferecendo uma solução técnica sólida, inovadora e adequada ao contexto real da BARTER. A

proposta de trabalho futuro apresentada tem potencial para colmatar as limitações atuais e melhorar substancialmente a eficácia prática da solução desenvolvida, contribuindo diretamente para o aumento da qualidade da experiência dos utilizadores finais da aplicação.

Bibliografia

- [AI, 2024] AI, N. (2024). nomic-embed-text documentation. Acedido em: 19 Julho 2025.
- [Brown et al., 2020] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., e Amodei, D. (2020). Language models are few-shot learners. In *Advances in Neural Information Processing Systems 33*, p. 1877–1901.
- [Covington et al., 2016] Covington, P., Adams, J., e Sargin, E. (2016). Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems, RecSys '16*, p. 191–198, New York, NY, USA. ACM.
- [Fowler, 2002] Fowler, M. (2002). *Patterns of Enterprise Application Architecture*. Addison-Wesley Signature Series. Addison-Wesley, Boston, MA, 1st edition.
- [Gamma et al., 1995] Gamma, E., Helm, R., Johnson, R., e Vlissides, J. (1995). *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley, Reading, MA, 1st edition.
- [Google, 2025] Google (2025). Machine learning: Recommendation systems guide. <https://developers.google.com/machine-learning/recommendation>. Acedido em: 20 de julho de 2025.
- [Grinberg, 2018] Grinberg, M. (2018). *Flask Web Development: Developing Web Applications with Python*. O'Reilly Media, 2nd edition.

- [Gómez-Uribe e Hunt, 2015] Gómez-Uribe, C. A. e Hunt, N. (2015). The netflix recommender system: Algorithms, business value, and innovation. *ACM Transactions on Management Information Systems*, 6(4):13:1–13:19.
- [Johnson et al., 2019] Johnson, J., Douze, M., e Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547.
- [Mikolov et al., 2013] Mikolov, T., Chen, K., Corrado, G., e Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- [Ollama, 2024] Ollama (2024). Ollama documentation.
- [Pennington et al., 2014] Pennington, J., Socher, R., e Manning, C. D. (2014). Glove: Global vectors for word representation. In *Proceedings of EMNLP 2014*, p. 1532–1543.
- [Vaswani et al., 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., e Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems 30*, p. 5998–6008.